GUIA METODOLÓGICO

Como construir um corpus semissintético de perguntas, respostas e evidências

Aplicado a RAG verificável para pesquisa em acervos históricos

Objetivo

Definir um procedimento reprodutível para gerar, validar e organizar um benchmark de perguntas históricas ancoradas em fontes reais, adequado para avaliar recuperação, geração, citação por afirmação, verificação de evidências e abstenção.

Princípio central

O conjunto deve ser semissintético: as perguntas podem ser geradas com LLMs, mas cada resposta de referência deve estar vinculada a evidências reais do acervo. O LLM não deve "inventar" a verdade de referência.

Documento-base

Proposta de dissertação "RAG verificável para pesquisa em acervos históricos", especialmente as seções sobre preparação do corpus, construção do conjunto de perguntas, avaliação de respostas/citações e mecanismos de abstenção.

Versão de trabalho para orientação e implementação.

1. O que deve ser construído

O produto não deve ser apenas uma lista de perguntas e respostas. O objeto de avaliação precisa registrar a relação entre pergunta, resposta esperada e evidência documental. Isso permite saber se um sistema acertou por usar a fonte correta ou se apenas produziu uma resposta plausível.

Unidade mínima do benchmark

Pergunta + resposta de referência + evidência(s) + metadados de dificuldade, tipo de pergunta e condição de respondibilidade.

1.1. Representação conceitual

```
Documento(s) D  ->  Evidência(s) E  ->  Pergunta Q  ->  Resposta de referência A

A deve ser derivável de E.
Q pode exigir uma ou várias evidências.
Se E for insuficiente, A deve indicar limitação ou abstenção.
```

1.2. Por que não gerar pergunta e resposta diretamente

O fluxo “documento -> LLM -> pergunta + resposta” é simples, mas metodologicamente frágil: o mesmo modelo pode introduzir uma interpretação indevida e depois tratá-la como verdade. O procedimento recomendado fixa primeiro a evidência e só depois gera a pergunta e a resposta de referência.

- A evidência é extraída e armazenada antes da geração da pergunta.
- A resposta de referência deve ser verificável diretamente na evidência.
- Perguntas não respondíveis devem ser construídas intencionalmente e rotuladas como tal.
- A validação final deve ser independente do modelo que gerou o item.

2. Pipeline recomendado

Etapa	Ação	Resultado
1	Selecionar a coleção	Definir subcoleção, tipologia documental, período e condições de acesso.
2	Preparar documentos	Preservar identificador, página/região, OCR original, OCR limpo e metadados.
3	Extrair evidências	Identificar afirmações, entidades, datas, eventos, relações e contradições.
4	Gerar perguntas	Criar itens factuais, temporais, relacionais, comparativos, multi-documento e adversariais.
5	Gerar resposta de referência	Produzir apenas o que pode ser sustentado pelas evidências selecionadas.
6	Validar automaticamente	Checar IDs, páginas, trechos, consistência entre resposta e evidência e duplicações.

Etapa	Ação	Resultado
7	Validar com especialista	Revisar plausibilidade histórica, sustentação documental e interpretação.
8	Separar Gold e Silver	Gold para resultados principais; Silver para desenvolvimento e testes auxiliares.

Regra operacional

A evidência de referência deve existir antes da pergunta. Em perguntas multi-documento, todas as evidências necessárias devem ser registradas explicitamente.

3. Etapa 1 - seleção e amostragem dos documentos

O benchmark deve representar a diversidade documental do recorte escolhido, mas sem ampliar o escopo a ponto de dificultar a validação humana. Para um primeiro ciclo, uma amostra controlada de documentos é mais útil do que tentar cobrir todo o acervo.

3.1. Critérios de amostragem

- Diferentes períodos, quando isso for relevante para a pergunta histórica.
- Diferentes tipos documentais dentro da coleção selecionada.
- Documentos com OCR de boa e de baixa qualidade.
- Documentos curtos e extensos.
- Documentos com alta e baixa densidade de entidades, datas e eventos.
- Documentos com possíveis divergências ou lacunas informacionais.

Sugestão prática

Começar com cerca de 100 a 150 documentos para a fase de geração do benchmark. O sistema de RAG pode indexar 300 a 1.000 documentos, conforme previsto no escopo da proposta, mas não é necessário usar todos eles para criar itens Gold.

4. Etapa 2 - extração de unidades de evidência

Cada documento deve ser dividido em trechos que mantenham contexto suficiente. A partir desses trechos, o sistema extrai unidades de evidência que podem dar origem às perguntas.

4.1. O que extrair

Tipo	Exemplos
Afirmações factuais	nomeações, funcionamento, existência de cursos, problemas registrados
Entidades	pessoas, instituições, cargos, localidades
Datas e períodos	datas explícitas, intervalos, sequência de eventos
Relações	pessoa-cargo, pessoa-instituição, evento-local
Eventos	criação, inauguração, encerramento, mudança administrativa
Avaliações documentais	críticas, justificativas, descrições de problemas

Tipo	Exemplos
Contradições potenciais	datas divergentes, nomes distintos, versões incompatíveis
Lacunas	informações sugeridas pelo contexto, mas não efetivamente documentadas

4.2. Exemplo de saída da etapa de evidência

```
{
  "evidence_id": "E0042",
  "document_id": "ATA_023",
  "page": 4,
  "text": "...existência de disciplinas sem docentes designados...",
  "claim": "Havia disciplinas sem professores designados em 1950.",
  "entities": ["Escola", "docentes"],
  "date": "1950",
  "evidence_type": "explicit",
  "ocr_quality": "good"
}
```

Importante

Guardar sempre o trecho original e a localização documental. Uma paráfrase gerada pelo LLM pode ser útil como claim normalizada, mas nunca deve substituir a evidência textual original.

5. Etapa 3 - estratégias de geração das perguntas

A melhor estratégia é híbrida. Em vez de depender de um único prompt, combine geração a partir de evidências, templates controlados, perguntas multi-documento e exemplos adversariais.

5.1. Perguntas derivadas de uma única evidência

Adequadas para itens factuais, temporais e descritivos. São úteis para medir recuperação direta e precisão das citações.

```
Evidência: "Em março de 1950 permaneciam sem professores as disciplinas de Agronomia e Zootecnia."

Pergunta: Quais disciplinas estavam sem professores em março de 1950?
Resposta: Agronomia e Zootecnia.
```

5.2. Perguntas multi-documento

Devem exigir duas ou mais evidências. Elas testam recuperação, agregação e geração sem fundir indevidamente fatos distintos.

```
Documento A (1949): insuficiência dos alojamentos.
Documento B (1951): capacidade dos dormitórios inferior à demanda.

Pergunta: Que problema relacionado à acomodação aparece nos documentos de 1949 e 1951?
Resposta: Ambos indicam insuficiência de alojamentos para os estudantes.
```

Meta recomendada

Fazer aproximadamente 30% a 40% do conjunto Gold exigir mais de uma evidência ou mais de um documento. Isso força o sistema a ir além de perguntas triviais de localização.

5.3. Geração a partir de entidades e relações

A extração prévia de entidades cria perguntas sistemáticas e reproduzíveis. Isso é útil para casos factuais, relacionais e temporais.

```
Pessoa: João Silva
Cargo: Diretor
Instituição: Escola Agrícola
Ano: 1951

Perguntas possíveis:
- Quem era diretor da Escola Agrícola em 1951?
- Qual cargo João Silva ocupava em 1951?
- A qual instituição João Silva estava vinculado?
```

5.4. Templates + paráfrase por LLM

Templates controlam a estrutura e o LLM fornece variação linguística. Isso reduz viés de estilo e evita que todas as perguntas sejam formuladas da mesma forma.

```
Template: Quem foi [CARGO] de [INSTITUIÇÃO] em [ANO]?
Template: Como [DOC_A] e [DOC_B] descrevem [EVENTO]?
Template: Quais documentos mencionam [ENTIDADE]?

Depois: pedir ao LLM 2 ou 3 paráfrases semanticamente equivalentes, sem alterar a informação necessária para a resposta.
```

6. Etapa 4 - geração de perguntas adversariais e de abstenção

O benchmark precisa conter perguntas sem resposta suficiente. Caso contrário, não será possível avaliar o mecanismo de abstenção previsto na proposta.

Tipo adversarial	Construção	Comportamento esperado
Informação ausente	Perguntar por um valor, causa ou detalhe não presente.	Abster-se ou indicar insuficiência.
Premissa falsa	Inserir na pergunta uma data, pessoa ou evento incompatível com a fonte.	Corrigir a premissa e não aceitá-la.
Causalidade não sustentada	Transformar associação documental em causa.	Responder com ressalva ou abster-se.
Contradição entre fontes	Selecionar duas fontes que divergem.	Preservar a divergência; não escolher arbitrariamente.
Hard negative temporal	Trocar o ano por outro muito próximo.	Não transferir a resposta para o ano errado.
Hard negative de entidade	Trocar pessoa/instituição por entidade semelhante.	Não completar por plausibilidade.

6.1. Pares respondível x não respondível

Uma estratégia eficiente é criar pares controlados. A versão positiva é respondível e a negativa altera apenas um elemento necessário.

```
Q+  Em que ano a escola iniciou suas atividades?
```

Q- Qual foi a principal motivação pessoal do diretor para iniciar as atividades?

Q+ Quanto a instituição recebeu em 1951?
Q- Quanto a instituição recebeu em 1952? [se 1952 não estiver documentado]

6.2. Níveis de saída esperada

Rótulo	Condição	Gold answer
SUPPORTED	Evidência suficiente e adequada.	Resposta direta com citação.
PARTIAL	Há indícios, mas falta sustentação completa.	Resposta limitada e explicitamente qualificada.
CONTRADICTORY	Fontes divergem.	Apresentar as versões e citar cada fonte.
UNANSWERABLE	Evidência ausente ou insuficiente.	Abstenção explícita e justificativa documental.

Cuidado

A categoria “não respondível” deve ser verificada por alguém que conheça o recorte documental. Não basta o LLM não encontrar a resposta em um trecho: a informação pode existir em outro documento do conjunto.

7. Taxonomia e composição do conjunto Gold

A classificação da pergunta deve ser multidimensional. Uma única pergunta pode ser, ao mesmo tempo, comparativa, multi-documento, parcialmente respondível, difícil e baseada em OCR ruidoso.

7.1. Distribuição sugerida para 80 itens Gold

Categoria principal	Quantidade
Factual / entidade	15
Temporal	10
Descritiva	10
Relacional	10
Comparativa / multi-documento	15
Exploratória	5
Contraditória	5
Não respondível	10
Total	80

7.2. Atributos independentes que devem ser anotados

Dimensão	Valores possíveis
Fonte	single-document / multi-document
Evidência	explicit / implicit-supported / partial / contradictory / absent
Respondibilidade	answerable / partial / unanswerable
OCR	clean / moderate / noisy
Distância lexical	low / medium / high
Raciocínio	lookup / temporal / relation / aggregation / comparison / contradiction
Dificuldade	easy / medium / hard

8. Etapa 5 - geração da resposta de referência

A gold answer não deve ser uma resposta “bonita”; deve ser uma resposta minimamente suficiente e completamente sustentada. Sempre que possível, separar a resposta em afirmações verificáveis.

- Uma afirmação por sentença, quando isso facilitar a associação com evidências.
- Não introduzir explicações históricas que não estejam documentadas no item.
- Em contradições, citar explicitamente cada versão.
- Em respostas parciais, indicar exatamente qual parte está sustentada e qual não está.
- Em abstenções, informar o tipo de evidência que seria necessário localizar.

Teste rápido

Pergunte: “Se eu remover do sistema todo conhecimento externo e deixar apenas as evidências registradas neste item, ainda é possível produzir a gold answer?” Se a resposta for não, o item precisa ser corrigido.

9. Estrutura recomendada para cada item

O esquema abaixo suporta avaliação de recuperação, geração, citação e abstenção, além de análises por tipo de pergunta e ruído de OCR.

```
{
  "id": "Q042",
  "question": "Quais dificuldades foram mencionadas ...?",
  "primary_type": "comparative",
  "reasoning": "multi_document",
  "answerability": "partial",
  "reference_answer": "...",
  "evidence": [
    {
      "doc_id": "ATA_23",
      "page": 4,
      "span": "...disciplinas sem docentes..."
    },
    {
      "doc_id": "REL_1952",
      "page": 17,
      "span": "...dificuldades no transporte..."
    }
  ],
  "required_documents": 2,
  "temporal_scope": "1948-1952",
  "ocr_quality": "good",
  "lexical_distance": "medium",
  "difficulty": "hard",
  "validation_status": "human_validated"
}
```

10. Etapa 6 - validação automática

Antes da revisão humana, execute filtros mecânicos e semânticos para reduzir o custo do especialista.

1. Verificar se todos os document_id, páginas e trechos citados existem.
2. Checar se cada pergunta possui pelo menos uma evidência, salvo itens intencionalmente não respondíveis.
3. Detectar perguntas duplicadas ou quase duplicadas.
4. Checar se a resposta contém nomes, datas ou números ausentes das evidências.
5. Usar um segundo modelo para julgar entailment entre evidência e resposta.
6. Sinalizar divergências entre o modelo gerador e o modelo verificador.
7. Rejeitar automaticamente itens com evidência truncada, ambígua ou mal localizada.

10.1. Separação de funções entre modelos

```
LLM A -> gera pergunta e resposta candidata
LLM B -> verifica se a resposta é sustentada pela evidência
Regras -> validam IDs, páginas, spans e metadados
Especialista -> valida o item final
```

Motivo

Evitar que o mesmo modelo gere e aprove o próprio erro. Modelos diferentes não eliminam o problema, mas reduzem self-consistency enganosa e tornam o processo mais auditável.

11. Etapa 7 - validação por historiadores ou especialistas

A revisão humana não precisa começar na geração. Ela deve ser concentrada nos itens candidatos que já passaram por filtros automáticos.

11.1. Checklist de validação humana

- A pergunta é plausível para uma pesquisa histórica real?
- A resposta está integralmente sustentada pelas evidências indicadas?
- A formulação elimina alguma ambiguidade relevante existente na fonte?
- A resposta introduz causalidade, intenção ou interpretação não documentada?
- As citações apontam para as páginas corretas?
- Uma pergunta marcada como não respondível é realmente não respondível no corpus selecionado?
- Em caso de contradição, todas as versões documentais relevantes foram preservadas?
- O item está difícil por razões historiograficamente legítimas, e não por má redação?

11.2. Gold e Silver

Conjunto	Construção	Uso recomendado
Gold	80-100 itens revisados detalhadamente por especialistas.	Resultados principais da dissertação; comparação final entre sistemas.

Conjunto	Construção	Uso recomendado
Silver	Centenas ou milhares de itens gerados e verificados automaticamente.	Desenvolvimento; testes de recuperação; análise de robustez; eventual treinamento auxiliar.

Boa prática

Não misturar os itens Silver na avaliação final sem identificá-los. A força do trabalho está em ter um conjunto Gold pequeno, controlado e auditável.

12. Prompts operacionais sugeridos

12.1. Extração de evidências

```
Você receberá um trecho documental histórico com identificador e página.
Extraia apenas afirmações explicitamente sustentadas pelo trecho.
Para cada afirmação, retorne: claim, evidence_span, entities, dates, relations, evidence_type.
Não use conhecimento externo. Não complete lacunas. Se algo for ambíguo, marque como ambíguo.
```

12.2. Geração de perguntas

```
Com base somente nas evidências fornecidas, gere perguntas de pesquisa em linguagem natural.
Cada pergunta deve indicar quais evidence_ids são necessários para respondê-la.
Gere itens de tipos variados: factual, temporal, relacional, comparativo e multi-documento.
Não gere perguntas cuja resposta exija conhecimento externo, exceto quando o item for explicitamente rotulado como unanswerable.
```

12.3. Verificação independente

```
Receba: pergunta, resposta candidata e evidências.
Classifique a resposta como SUPPORTED, PARTIAL, CONTRADICTORY ou UNSUPPORTED.
Liste cada afirmação da resposta e a evidência que a sustenta.
Se uma afirmação introduzir informação não presente nas evidências, marque-a como unsupported.
```

13. Controle de qualidade e divisão experimental

13.1. Evitar vazamento entre desenvolvimento e teste

A divisão do benchmark deve considerar documentos, e não apenas perguntas. Se perguntas sobre o mesmo documento aparecem em treino/desenvolvimento e teste, o sistema pode se beneficiar de padrões documentais já observados.

- Preferir split por documento ou por grupo de documentos relacionados.
- Manter perguntas para ajuste de prompts separadas do conjunto Gold de teste.
- Congelar o Gold antes de executar os experimentos finais.
- Versionar corpus, índice, prompts e modelos usados na geração e verificação.

13.2. Auditorias úteis

Auditoria	Pergunta de controle
Cobertura	Os principais tipos de pergunta estão representados?
Balanceamento	Há itens fáceis e difíceis; respondíveis e não respondíveis?

Auditoria	Pergunta de controle
Proveniência	Toda evidência é rastreável à página e ao documento?
Sustentação	Toda afirmação da gold answer está apoiada?
Diversidade lexical	Existem paráfrases e perguntas que não copiam literalmente a fonte?
Hard negatives	Há casos em que pequenas mudanças tornam a pergunta não respondível?
OCR	Há itens suficientes para medir efeito de ruído de OCR?

14. Como o corpus se conecta à avaliação do RAG

O mesmo item deve permitir avaliar diferentes etapas da arquitetura. Isso é uma vantagem central do esquema proposto.

Componente avaliado	Campo do benchmark utilizado
Recuperação	evidence.doc_id, page, span
Reranking	ordem das evidências relevantes recuperadas
Resposta	reference_answer e rótulo de sustentação
Citação	mapeamento afirmação -> evidence_id
Abstenção	answerability e condição esperada
Robustez a OCR	ocr_quality
Análise por dificuldade	difficulty, reasoning, lexical_distance

Resultado

O benchmark deixa de ser apenas um teste de “acerto da resposta” e passa a medir onde o sistema falhou: recuperação, seleção, geração, citação, verificação ou decisão de se abster.

15. Plano prático de execução

Abaixo está uma sequência compatível com o cronograma da proposta e que pode ser executada em ciclos curtos antes da geração do conjunto definitivo.

Fase	Atividade	Saída
Piloto 1	Selecionar 10-20 documentos; extrair evidências; gerar 20 perguntas.	Validar prompts, schema e granularidade.
Piloto 2	Adicionar multi-documento e perguntas adversariais.	Verificar se o sistema mede abstenção e contradição.
Silver	Executar geração em lote e filtros automáticos.	300-500 itens candidatos.
Curadoria	Selecionar itens por cobertura, dificuldade e diversidade.	120-150 itens para revisão.
Gold	Revisão por especialistas e correções finais.	80-100 itens auditáveis.
Congelamento	Versionar e bloquear conjunto final.	Benchmark final para experimentos.

16. Critérios de aceitação de um item Gold

- A pergunta é clara e não depende de contexto ausente.

- As evidências necessárias estão identificadas e localizáveis.
- A gold answer é derivável apenas dessas evidências.
- O rótulo de respondibilidade é justificável.
- O tipo e a dificuldade da pergunta foram anotados.
- Não há informação acrescentada por conhecimento externo do LLM.
- O item passou por verificação automática e revisão humana.
- O item não duplica semanticamente outro item do conjunto Gold.

17. Síntese da recomendação

O melhor desenho para a dissertação é construir um benchmark semissintético, e não um corpus totalmente artificial. A geração por LLM deve acelerar a criação das perguntas e das paráfrases, enquanto a verdade de referência permanece ancorada no acervo. A contribuição científica fica mais forte quando o conjunto registra evidências granulares, casos multi-documento, perguntas não respondíveis, contradições e metadados que permitam analisar sistematicamente cada falha do RAG.

Fluxo final recomendado

Acervo -> evidências -> geração de perguntas -> resposta de referência -> verificação automática -> revisão humana -> Gold/Silver -> experimentos de RAG.

18. Checklist de implementação

- ☐ Definir coleção-piloto e documentos elegíveis.
- ☐ Definir schema JSON do benchmark.
- ☐ Implementar extração de evidências e provenance.
- ☐ Criar prompts de geração e verificação.
- ☐ Gerar primeiro lote piloto.
- ☐ Construir hard negatives e itens de abstenção.
- ☐ Definir protocolo de revisão humana.
- ☐ Criar conjuntos Silver e Gold.
- ☐ Congelar o Gold antes dos experimentos finais.
- ☐ Publicar schema, prompts, versão do corpus e critérios de validação junto ao artigo/dissertação.