PROPOSTA DE TEMA
DE DISSERTAÇÃO

RAG verificável para pesquisa em acervos históricos

Desenvolvimento e avaliação de respostas conversacionais com evidências, citações granulares e mecanismos de abstenção

Mestrado em Humanidades Digitais
Documento de trabalho • julho de 2026

Visão geral

A proposta investiga em que condições um sistema conversacional consegue responder a perguntas históricas mantendo cada afirmação vinculada a evidências documentais adequadas. O objetivo não é simplesmente construir um chatbot para o RIMA, mas desenvolver e avaliar mecanismos que tornem as respostas verificáveis, transparentes quanto aos seus limites e úteis à pesquisa histórica.

> *Título provisório*
> *Desenvolvimento e avaliação de um sistema RAG verificável, com citações e mecanismos de abstenção, para apoio à pesquisa em acervos históricos digitais.*

1. Problema de pesquisa

Sistemas de geração aumentada por recuperação (Retrieval-Augmented Generation - RAG) recuperam documentos antes de gerar uma resposta. Essa estratégia reduz a dependência do conhecimento interno do modelo, mas não garante que a resposta esteja efetivamente apoiada nas fontes.

Entre as falhas possíveis estão:

- o documento correto não ser recuperado;
- o trecho recuperado tratar do assunto, mas não conter a resposta;
- o modelo utilizar conhecimento prévio em vez da fonte;
- a resposta citar um documento que não sustenta a afirmação;
- informações de documentos diferentes serem combinadas como se fossem um único fato;
- uma conclusão categórica ser produzida diante de fontes insuficientes ou contraditórias;
- erros de OCR alterarem nomes, datas e lugares;
- ambiguidades relevantes à interpretação histórica serem eliminadas pela resposta.

> *Assim, não basta perguntar se o sistema apresenta uma resposta correta. É necessário investigar se a resposta é sustentada pelas fontes, se preserva as ambiguidades documentais e se permite ao pesquisador verificar como foi produzida.*

2. Questões de pesquisa e hipóteses

Questão principal: Em que medida mecanismos de verificação de evidências, citações granulares e abstenção reduzem a produção de afirmações não sustentadas por um sistema RAG aplicado a um acervo histórico digital?

Questões secundárias

- A busca híbrida recupera evidências melhores do que a busca exclusivamente vetorial?
- A apresentação de mais documentos melhora ou prejudica a resposta?
- Um segundo estágio de verificação detecta afirmações sem apoio documental?
- A exigência de citações por afirmação reduz alucinações?
- Quando o sistema deve responder, apresentar uma hipótese ou se abster?
- Como erros de OCR afetam a recuperação e a geração?
- Historiadores verificam mais facilmente as respostas do sistema proposto?

Hipótese principal

> *Um sistema RAG que combine recuperação híbrida, reordenação de documentos, citação por afirmação, verificação posterior e regras de abstenção produzirá menos afirmações não sustentadas e facilitará a verificação das respostas quando comparado a um RAG convencional.*

Como hipótese complementar, espera-se que a melhoria não seja uniforme: perguntas factuais devem se beneficiar mais, enquanto perguntas interpretativas, comparativas e exploratórias continuarão exigindo maior intervenção do historiador.

3. Delimitação do estudo

O trabalho não deve abranger inicialmente todo o RIMA. Recomenda-se selecionar uma coleção específica, uma tipologia documental relativamente homogênea e um conjunto de documentos com direitos e condições de acesso conhecidos.

- uma coleção ou subcoleção específica;
- aproximadamente 300 a 1.000 documentos, conforme sua extensão;
- entre 60 e 100 perguntas de avaliação;
- um subconjunto menor revisado detalhadamente por historiadores;
- vínculo entre texto, metadados, página e imagem original.

Possíveis recortes incluem atas, relatórios administrativos, correspondências, periódicos históricos, processos institucionais ou documentos relativos a uma instituição, período ou acontecimento da Baixada Fluminense.

4. Exemplo concreto

Para ilustrar, considere uma coleção hipotética de atas e relatórios referentes à criação e ao funcionamento de uma escola agrícola. Um pesquisador formula a seguinte pergunta:

> *Quais dificuldades foram mencionadas para o funcionamento da escola entre 1948 e 1952?*

Resposta de um RAG convencional

> *“Entre 1948 e 1952, a escola enfrentou falta de professores, problemas de transporte, insuficiência de alojamentos e redução do financiamento federal.”*

A resposta parece plausível, mas a inspeção das fontes revela que falta de professores, transporte e alojamentos são mencionados nos documentos, enquanto a alegada redução do financiamento federal não é. Um relatório registra apenas atraso no repasse. O modelo transformou essa informação em outra afirmação.

Resposta esperada de um RAG verificável

> *Os documentos localizados mencionam três dificuldades:*
>
> *1. Falta de professores, registrada na ata de 14 de março de 1950, que informa a existência de disciplinas sem docentes designados [Ata 23, p. 4].*
>
> *2. Problemas de transporte, mencionados no relatório de 1952 como causa de dificuldades no deslocamento dos estudantes [Relatório anual de 1952, p. 17].*
>
> *3. Insuficiência de alojamentos, registrada nos relatórios de 1949 e 1951 [Relatório de 1949, p. 8; Relatório de 1951, p. 11].*
>
> *Um documento menciona atraso no recebimento de recursos, mas as fontes recuperadas não permitem concluir que houve redução do financiamento federal [Ofício 31/1951, p. 2].*

Nesse segundo caso, o sistema:

- divide a resposta em afirmações verificáveis;
- associa cada afirmação a uma evidência;
- diferencia informação explícita de interpretação;
- evita converter “atraso no repasse” em “redução do financiamento”;
- indica claramente os limites das fontes recuperadas.

5. Exemplo de abstenção

Considere agora a pergunta: “A falta de financiamento foi a principal causa do encerramento da escola?” Os documentos recuperados mencionam dificuldades financeiras, mas não contêm informação suficiente sobre a decisão de encerramento.

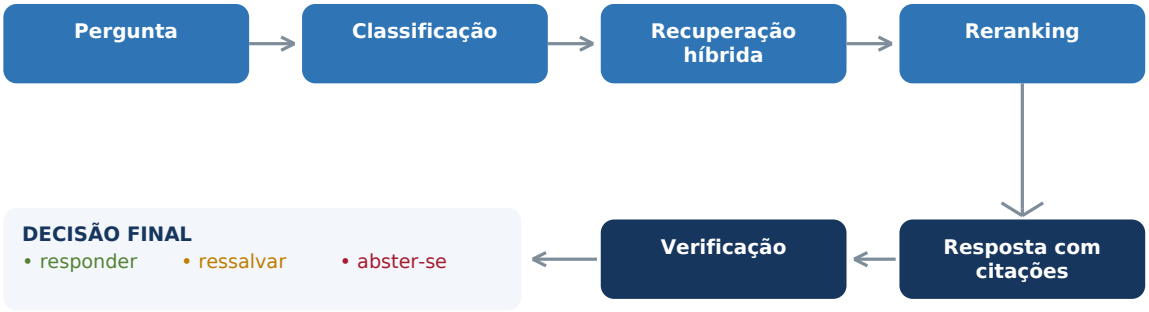
> *Os documentos recuperados mencionam dificuldades financeiras, mas não são suficientes para determinar se essa foi a principal causa do encerramento. Para responder à pergunta, seria necessário localizar documentos relacionados especificamente à decisão de encerramento.*

A decisão do sistema pode assumir três níveis:

Nível	Condição	Saída
Resposta sustentada	Existem evidências suficientes e adequadas.	Responder com citações.
Resposta parcial	Existem indícios, mas não evidência conclusiva.	Responder com ressalvas ou apresentar hipótese.
Abstenção	As fontes são insuficientes, ausentes ou contraditórias.	Explicitar a limitação e indicar o que seria necessário buscar.

6. Arquitetura experimental

O sistema organiza a consulta em etapas separadas, permitindo avaliar onde cada erro se origina: na recuperação, na seleção dos trechos, na geração, na citação ou na verificação final.



6.1 Preparação do corpus

- extração de textos e metadados autorizados do RIMA;
- preservação do identificador persistente de cada documento;
- associação entre texto, página ou região e imagem original;
- limpeza controlada do OCR, mantendo também a versão de origem;
- segmentação dos documentos em trechos;
- registro de coleção, data, autoria, tipologia e contexto arquivístico.

A granularidade dos trechos deve ser avaliada experimentalmente. Trechos muito pequenos perdem contexto; trechos muito grandes podem misturar acontecimentos, entidades e períodos.

6.2 Recuperação

Configuração	Descrição
Lexical	Recuperação baseada em palavras, nomes e expressões exatas.
Vetorial	Recuperação baseada em similaridade semântica e paráfrases.
Híbrida	Combinação de resultados lexicais e vetoriais.
Híbrida + reranker	Reordenação dos candidatos por um modelo adicional.

6.3 Geração

O modelo receberá os trechos mais relevantes e instruções para:

- utilizar somente as fontes fornecidas;
- não completar informações ausentes;
- citar documento e página para cada afirmação relevante;
- separar fatos documentados de inferências;
- indicar contradições entre documentos;
- abster-se quando as evidências forem insuficientes.

6.4 Verificação das afirmações

A resposta será decomposta em unidades verificáveis. Por exemplo, a frase “A escola enfrentou falta de docentes em 1950 e reduziu suas atividades em 1951” contém pelo menos duas afirmações independentes. Cada uma será classificada como sustentada, parcialmente sustentada, contradita ou sem evidência.

Afirmações sem sustentação poderão ser removidas, reescritas como hipótese ou provocar a abstenção do sistema, conforme regras definidas no experimento.

7. Construção do conjunto de perguntas

As perguntas devem ser formuladas com a participação de historiadores e vinculadas a evidências esperadas. O conjunto precisa contemplar diferentes operações de pesquisa e incluir perguntas deliberadamente não respondíveis.

Classe	Exemplo
Factual	Quem assinou o documento?
Temporal	Em que ano a instituição começou a funcionar?
Descritiva	Quais dificuldades foram registradas no relatório?
Relacional	Quais pessoas aparecem vinculadas à instituição?
Comparativa	Como os relatórios de 1950 e 1952 descrevem o problema?
Agregativa	Quantos documentos mencionam determinada organização?
Exploratória	Quais documentos podem ajudar a investigar a participação feminina?
Não respondível	Qual foi a opinião pessoal do diretor sobre o encerramento?
Contraditória	Qual data de inauguração é apresentada pelas diferentes fontes?

Exemplo de distribuição para 80 perguntas

Classe	Quantidade
Factual	20
Temporal	10
Descritiva	10
Comparativa	10
Relacional	10
Exploratória	10
Não respondível ou contraditória	10

A inclusão de perguntas sem resposta é indispensável. Se todas tiverem respostas explícitas no corpus, o experimento não conseguirá medir adequadamente quando o sistema deve se abster.

8. Configurações comparadas

Sistema	Componentes	Papel no experimento
A — LLM sem recuperação	Resposta apenas com conhecimento paramétrico.	Controle para conteúdos locais ou pouco conhecidos.
B — RAG convencional	Busca vetorial, primeiros trechos e referências gerais.	Linha de base do sistema de recuperação.
C — RAG verificável	Busca híbrida, reranker, metadados, citação por afirmação, verificação e abstenção.	Proposta principal da dissertação.

A contribuição não está apenas em demonstrar que RAG supera um LLM sem acesso ao acervo. O objetivo é identificar quais mecanismos tornam o RAG efetivamente mais verificável no contexto da pesquisa histórica.

9. Estratégia de avaliação

A avaliação deve separar a qualidade da recuperação, a qualidade da resposta e a decisão de responder ou se abster. Uma resposta ruim pode decorrer de evidência não recuperada, uso incorreto de evidência correta ou geração sem sustentação.

9.1 Recuperação

- Recall@k e Precision@k;
- Mean Reciprocal Rank (MRR);
- Normalized Discounted Cumulative Gain (nDCG);
- proporção de perguntas para as quais a evidência correta foi recuperada;
- desempenho por tipo de pergunta e nível de ruído de OCR.

9.2 Resposta e citações

- correção factual, relevância e completude;
- proporção de afirmações sustentadas, contraditas ou sem evidência;
- taxa de informações inventadas;
- correção das citações: a fonte citada realmente sustenta a afirmação;
- cobertura das citações: todas as afirmações relevantes possuem evidência.

9.3 Abstenção

- perguntas respondíveis corretamente respondidas;
- perguntas não respondíveis que geraram abstenção;
- perguntas respondíveis indevidamente recusadas;
- perguntas sem evidência que receberam resposta categórica;
- precisão, revocação e F1 adaptadas à decisão de responder ou se abster.

9.4 Avaliação humana

Historiadores ou especialistas receberão a pergunta, a resposta, as citações, os trechos recuperados e acesso à página original. Poderão avaliar:

- correção da resposta;
- sustentação de cada afirmação;
- adequação das fontes citadas;
- preservação de ambiguidades e contradições;
- presença de inferências indevidas;
- utilidade para uma pesquisa real;
- facilidade de verificar como a resposta foi produzida.

Escalas quantitativas podem ser combinadas com justificativas abertas e estudos de casos. A análise qualitativa dos erros é especialmente importante porque uma mesma taxa média pode ocultar falhas historicamente muito distintas.

10. Enquadramento em Humanidades Digitais

Para que a dissertação não seja apenas um projeto de Engenharia de Software, ela deve analisar criticamente a mediação computacional das fontes.

- diferença entre resposta documental e interpretação histórica;
- risco de o sistema apresentar uma narrativa única;

- contradições, lacunas e silêncios do acervo;
- diferença entre relevância algorítmica e relevância historiográfica;
- efeito do OCR sobre a visibilidade de pessoas e grupos;
- confiança gerada por citações, mesmo quando usadas incorretamente;
- limites da automação na crítica documental.

> *O sistema não pretende responder "o que aconteceu" de maneira definitiva, mas indicar o que determinadas fontes recuperadas permitem afirmar sobre a pergunta formulada.*

11. Objetivos

Objetivo geral

> *Desenvolver e avaliar uma arquitetura RAG verificável para consulta a uma coleção histórica do RIMA-UFRRJ, investigando como recuperação híbrida, citações granulares, verificação de afirmações e mecanismos de abstenção afetam a sustentação documental e a utilidade das respostas para a pesquisa histórica.*

Objetivos específicos

- selecionar uma coleção-piloto e caracterizar suas condições documentais e arquivísticas;
- construir um corpus de perguntas com evidências esperadas;
- comparar métodos de recuperação lexical, vetorial e híbrida;
- desenvolver um mecanismo de geração com citações por afirmação;
- implementar uma etapa de verificação entre afirmações e evidências;
- definir critérios para resposta, resposta parcial e abstenção;
- avaliar tecnicamente a recuperação, as respostas e as citações;
- avaliar a utilidade e a verificabilidade com historiadores;
- analisar erros e suas implicações para a pesquisa histórica.

12. Produtos esperados

- corpus de perguntas históricas com evidências;
- índice de busca da coleção selecionada;
- protótipo de RAG verificável;
- módulo de verificação e abstenção;
- protocolo de avaliação;
- taxonomia de erros;
- diretrizes para integração futura ao RIMA;
- artigo interdisciplinar sobre IA verificável em acervos históricos.

13. Escopo mínimo e extensões

Parte obrigatória

- uma coleção;
- 60 a 100 perguntas;
- busca lexical, vetorial e híbrida;
- RAG convencional versus RAG verificável;

- citações por afirmação;
- mecanismo de abstenção;
- avaliação técnica e análise de erros;
- participação de especialistas na construção ou validação do corpus.

Extensões opcionais

- interface integrada ao RIMA;
- exibição da região exata da imagem;
- comparação de diferentes LLMs;
- consultas ao grafo de conhecimento;
- estudo com um número maior de usuários;
- perguntas multilíngues;
- estudo sistemático do ruído de OCR;
- detecção automática de contradições entre documentos.

As extensões não devem integrar o núcleo obrigatório, pois ampliariam consideravelmente o risco de escopo da dissertação.

14. Cronograma indicativo de 24 meses

Período	Atividade
Meses 1–3	Revisão, escolha da coleção e definição das perguntas.
Meses 4–6	Preparação do corpus e das evidências de referência.
Meses 7–9	Implementação das buscas lexical, vetorial e híbrida.
Meses 10–12	Implementação e validação do RAG convencional.
Meses 13–15	Citações granulares, verificação e abstenção.
Meses 16–18	Experimentos e análise quantitativa.
Meses 19–20	Avaliação com especialistas.
Meses 21–22	Análise crítica e redação.
Meses 23–24	Ajustes, produção de artigo e defesa.

15. Síntese da proposta

O melhor recorte não é “criar um chatbot histórico”, mas investigar como construir respostas verificáveis sobre uma coleção histórica específica. O protótipo funciona como instrumento para responder à pergunta científica, e não como resultado exclusivo da dissertação.

A originalidade encontra-se na articulação entre recuperação de informação, verificação automática, crítica documental e avaliação com especialistas. A pesquisa poderá oferecer uma contribuição computacional reutilizável pelo projeto maior e, ao mesmo tempo, discutir como sistemas de IA mediam o acesso, a interpretação e a confiança em fontes históricas digitais.

> *Formulação resumida:*
> *Como produzir respostas conversacionais úteis à pesquisa histórica sem ocultar as fontes, as incertezas e os limites do acervo?*